

GPT分析结果

数据和口径

本轮只使用 `analysis/data_{dataset}_{arch}_no_nc.csv/json`，主统计共 1491 个配置点：CIFAR-10 -> STL-10 为 513，MNIST-M -> MNIST 为 513，Tiny-ImageNet -> ImageNetV2 对应类别为 465。我没有使用任何 NC 字段。

指标方向如下，后面所有结论都按这个方向解释：

- `transfer_rate` 越高，目标域 ASR 越高，迁移性越强。
- `weighted_TPR = 1 - stealth_tpr_avg`，越高表示越容易被四种防御检出。
- `weighted_AUC = 1 - stealth_auc_avg`，越高表示越容易被四种防御区分 clean/poison。
- `stealth_TPR_w = stealth_tpr_avg`，越高表示越隐蔽。
- `stealth_AUC_w = stealth_auc_avg`，越高表示越隐蔽。
- raw TPR / raw AUC 越高，都表示越容易检测。

当前 no-NC 主表每行都有 `transfer_rate`, `asr`, `stealth_tpr_avg`, `stealth_auc_avg`。我又按配置和 `transfer_rate/asr` 精确回匹配了原始跨域 txt 与 `test_results*.json`，为 1491/1491 行补到了目标域 clean ACC 和源域 clean ACC。目标域 clean ACC 均值：CIFAR-10 -> STL-10 为 0.648，MNIST-M -> MNIST 为 0.942，Tiny-ImageNet -> ImageNetV2 对应类别为 0.360。Tiny 的目标域 ACC 较低，所以 Tiny 上的 `transfer_rate` 解释要更谨慎。

总体结论

总体上，数据支持“迁移性越强，越容易被检测，隐蔽性越差”的 trade-off，但它不是无例外的规律。AUC 口径和 TPR 口径方向一致，AUC 相关性更强，也更适合作为主结论，因为 AUC 不依赖固定阈值，而 TPR 是阈值化后的操作点，受每个防御阈值校准影响更大。

子集	N	transfer vs wTPR Pearson / Spearman	transfer vs wAUC Pearson / Spearman	transfer vs stTPR	transfer vs stAUC
全部配置	1491	+0.599 / +0.633	+0.660 / +0.684	-0.599	-0.660
asr ≥ 0.3	1120	+0.414 / +0.469	+0.463 / +0.487	-0.414	-0.463
asr ≥ 0.5	1003	+0.354 / +0.421	+0.383 / +0.412	-0.354	-0.383

解释是：

- 全量数据中，transfer_rate 与 weighted_TPR/weighted_AUC 明显正相关，说明高迁移点通常更容易被检测。
- 等价地，transfer_rate 与 stealth_TPR_w/stealth_AUC_w 明显负相关，说明高迁移点通常隐蔽性更差。
- 但过滤到 asr >= 0.3 或 asr >= 0.5 后，相关性仍为正但明显变弱。这说明全局 trade-off 一部分来自“攻击未建立成功的点”：这些点常常低迁移、低检测、高 stealth，不能简单解释为真正隐蔽。
- 因此主结论应写成：总体存在正向迁移-检测关系，支持 trade-off；但 trade-off 强度依赖数据集、模型架构和攻击机制，且存在高迁移高隐蔽反例，尤其是 MNIST-M -> MNIST 上的 UPGD、BELT 和部分 Blend/WaNet。

分数据集

迁移设置	N	mean transfer	mean wTPR	mean wAUC	transfer-wAUC Pearson / Spearman	asr>=0.5 后 transfer-wAUC
CIFAR-10 -> STL-10	513	0.593	0.433	0.674	+0.706 / +0.751	+0.590 / +0.669
MNIST-M -> MNIST	513	0.603	0.330	0.545	+0.699 / +0.760	+0.458 / +0.561
Tiny-ImageNet -> ImageNetV2 对应类别	465	0.746	0.380	0.697	+0.705 / +0.754	+0.484 / +0.514

CIFAR-10 -> STL-10 的 trade-off 很明显。basic/BadNet 是最典型的高迁移高检测攻击，很多配置 transfer_rate 接近 1.0，同时 weighted_AUC 接近 0.97，stealth_AUC_w 只有 0.02-0.03。CIFAR 上也有源域攻击成功但迁移失败的典型点，主要是 WaNet：例如 resnet18, WaNet, poison_rate=0.01, s=0.8, asr=0.888 但 transfer_rate=0.0416，说明源域后门建立了，但空间形变 cue 没有很好跨到 STL-10。CIFAR 的反例较少；一个相对反例是 resnet18, blend, poison_rate=0.005, alpha=0.3, transfer_rate=0.936、weighted_AUC=0.523、stealth_AUC_w=0.478，但它只是“相对低检测”，不如 MNIST-M 上的反例强。

MNIST-M -> MNIST 的全局相关性也支持 trade-off，但反例最集中。basic 仍然是高迁移高检测：transfer_rate 常到 1.0，weighted_AUC 可达 0.85+。但 UPGD、BELT、部分 Blend 和 WaNet 能同时做到高迁移和较低检测。例如 resnet18, upgd, poison_rate=0.05, eps=20 的 transfer_rate=0.9985，但 weighted_AUC=0.3608、stealth_AUC_w=0.6392，且 asr=0.889，不是攻击失败。MNIST-M 的目标域 clean ACC 均值 0.942，所以这些反例不能简单归因于目标域分类不可靠。

Tiny-ImageNet -> ImageNetV2 对应类别的 trade-off 也明显，尤其是 basic、adaptive_patch、belt：高迁移通常伴随高 weighted_AUC。例如 Tiny 上 basic 平均 transfer_rate=0.882、weighted_AUC=0.889；adaptive_patch 平均 transfer_rate=0.849、weighted_AUC=0.879。这里类别映射已按上一轮确认：结果文件名叫 test_tiny_target_domain_results*.txt，代码命名是 tiny_target_domain，但目标域路径是 /workspace/data/imagenetv2-matched-frequency-tiny-organized，并通过 class_to_idx / Tiny-ImageNet wnid 对齐检查。因此后续论文口径应写为“Tiny-ImageNet -> ImageNetV2 对应类别”，同时说明代码文件名不是 ImageNetV2。限制是目标域 clean ACC 均值只有 0.360，所以 Tiny 上的 ASR/transfer 解释要带上这一可靠性限制。

分模型架构

arch	N	mean transfer	mean wTPR	mean wAUC	mean stAUC	transfer-wAUC Pearson / Spearman	asr>=0.5 后 transfer-wAUC
mobilenet	497	0.622	0.367	0.626	0.374	+0.657 / +0.665	+0.385 / +0.425
resnet18	497	0.691	0.389	0.661	0.339	+0.645 / +0.622	+0.318 / +0.318
vgg	497	0.618	0.387	0.623	0.377	+0.671 / +0.726	+0.451 / +0.490

ResNet18 平均迁移性最高：mean transfer=0.691，同时平均检测强度也最高：mean wAUC=0.661。这说明 ResNet18 更容易出现“迁移强、检测也强”的整体趋势。迁移性最高的攻击主要是 basic, blend, belt, WaNet/adaptive_blend；最容易检测的是 basic，其次是 belt/adaptive_patch。但 ResNet18 也有高迁移高隐蔽反例，集中在 MNIST-M 的 UPGD/BELT，比如 upgd eps=20。

MobileNet 的全局 trade-off 也明显，transfer-wAUC Spearman=0.665。按极端点计数，MobileNet 上高迁移高检测点最多，主要来自 Tiny 和 CIFAR 的 basic。同时它也最容易出现 MNIST-M 上的高迁移高隐蔽反例，如 belt、upgd、blend。MobileNet 上平均 stTPR 最高，但按 AUC 主口径，隐蔽性最高的是 VGG。

VGG 的平均迁移不最高，但 trade-off 相关性最强，尤其 Spearman AUC 为 0.726，asr>=0.5 后仍有 0.490。VGG 上 basic 仍是最高迁移和最高检测攻击；upgd 和部分 WaNet 更容易形成反例或迁移失败点。VGG 也有一个重要反例：Tiny-ImageNet -> ImageNetV2 对应类别中 vgg, upgd, poison_rate=0.001, eps=24，transfer_rate=0.896、weighted_AUC=0.412、stealth_AUC_w=0.588、asr=0.746。

模型比较结论是：**VGG 上相关性最强，ResNet18 上平均迁移性和平均检测强度最高，MobileNet 上极端高迁移高检测点和高迁移高隐蔽反例都较多。模型架构不会推翻总体 trade-**

off，但会明显调节 trade-off 的强弱和反例类型。论文不应只写一个全局结论，应写成模型相关现象。

分攻击方法

attack_type	mean ASR	mean transfer	mean wTPR	mean wAUC	mean stAUC	解释
basic	0.848	0.885	0.733	0.852	0.148	最支持 trade-off：高迁移、高检测、低隐蔽。
belt	0.860	0.767	0.438	0.708	0.292	平均支持 trade-off，但 MNIST-M 上有高迁移高隐蔽反例。
blend	0.750	0.757	0.327	0.637	0.363	中高迁移、中等检测；MNIST-M 中等 alpha 可成为反例。
adaptive_patch	0.497	0.625	0.498	0.671	0.329	一旦迁移成功，检测也强，支持 trade-off。
adaptive_blend	0.565	0.598	0.252	0.566	0.434	温和 trade-off；cover/masked blend 带来较高隐蔽性。
upgd	0.570	0.569	0.256	0.545	0.455	最重要反例来源之一；有效子集中迁移高但检测仍低。
WaNet	0.618	0.566	0.290	0.580	0.420	数据集依赖强；CIFAR 上大量高 ASR 低迁移。
SIG	0.341	0.302	0.186	0.486	0.514	低检测但很多点 ASR 低，不能直接当作成功隐蔽攻击。

逐个攻击看：

- BELT / belt：整体迁移强，检测强度中高，平均上支持 trade-off。但它也是反例来源，尤其 MNIST-M 上 transfer_rate 可到 1.0，weighted_AUC 仍只有 0.43-0.45。机制上它仍是局部 patch，但 cover samples + CenterLoss 的 BELT 增强训练会削弱简单特征分离，因此比普通 BadNet 更不容易被四防御平均检测。
- UPGD / upgd：整体均值中等，但在 asr>=0.5 子集里 mean transfer=0.837，mean wAUC=0.618，比 BadNet 隐蔽得多。它经常构成 trade-off 反例，尤其 MNIST-M 和个别

Tiny/VGG 配置。机制上 UPGD 是优化扰动，不是局部显著 patch，SentiNet 这类局部显著区域检测不占优势。

- BadNet / basic：最清晰支持主问题。局部 patch 强、ASR 高、transfer 高，但 weighted_TPR/weighted_AUC 也最高，stealth_AUC_w 最低。poison_rate 和 alpha 增大时，迁移和检测通常一起升高。
- Blend / blend：迁移性强于 adaptive_blend/UPGD/WaNet 的总体均值，但检测不如 basic；因此只中等支持 trade-off。MNIST-M 上存在高迁移高隐蔽反例，因为全图 blend 不形成紧凑显著区域，且中等 alpha 下预测稳定性未必被四防御同时抓住。
- SIG：整体迁移弱、检测低、隐蔽高，但主要受 ASR 低影响。特别是 MNIST-M 的 SIG 平均 asr=0.028、transfer=0.003，应解释为攻击未建立成功，而不是“成功且隐蔽”。在 asr>=0.5 后，SIG 的 mean transfer=0.716、mean wAUC=0.556，AUC 口径仍显示一定 trade-off，TPR 口径较弱。
- Adaptive-Patch / adaptive_patch：强支持 trade-off。虽然它有 cover samples 和多 patch 训练，但本质仍是局部 patch；迁移成功时显著区域和预测稳定性更容易被 SentiNet/STRIP/Scale-Up/IBD-PSC 捕捉。Tiny 上尤其明显。
- Adaptive-Blend / adaptive_blend：支持较弱但方向一致。masked trigger 和 cover samples 分散了检测信号，因此比 basic/adaptive_patch 更隐蔽；但 poison_rate 提高时，ASR、transfer 和 wAUC 仍一起上升。
- WaNet：不是单一结论。MNIST-M 上可高迁移且相对低检测；CIFAR 上大量 WaNet 是高 ASR 但低 transfer，说明空间形变 cue 在 CIFAR->STL 的跨域迁移失败。机制上它没有显式局部像素图案，对 SentiNet/Scale-Up 不天然友好，但强形变或高 poison_rate 仍会提高检测强度。

交互效应

存在明显的数据集 × 模型 × 攻击交互。

- basic 几乎在所有数据集和模型上都表现出 trade-off：高迁移、高检测、低隐蔽。
- adaptive_patch 在 Tiny 和 CIFAR 上更接近 basic；在 MNIST-M 上许多配置 ASR 不高，解释时要先过滤攻击失败点。
- upgd 的反例性最依赖数据集和模型：MNIST-M 上最明显，Tiny/VGG 也出现，CIFAR 上较少。
- WaNet 的排序变化最大：MNIST-M 可高迁移，CIFAR 经常高 ASR 低 transfer，Tiny 上随 s/poison_rate 增强后更接近 trade-off。
- 高迁移高检测配置最集中在 Tiny-ImageNet 的 basic/adaptive_patch/belt 和 CIFAR 的 basic；高迁移高隐蔽反例最集中在 MNIST-M 的 upgd/belt/blend，其次是 Tiny 的个别 UPGD/SIG。
- 全局相关性不是纯粹的混合假象，因为三个数据集、三个模型内相关性都为正；但过滤 asr>=0.5 后相关性明显变弱，说明攻击失败点和攻击家族混合确实放大了全局 trade-off。

控制指标检查

asr 控制后，主结论仍成立但更弱：asr>=0.5 子集里，transfer_rate 与 weighted_AUC 仍有 Pearson=0.383、Spearman=0.412。这说明 trade-off 不是只由失败攻击造成，但失败攻击会夸大全局相关性。

高 ASR 低 transfer 的典型是 CIFAR 的 WaNet。例如 cifar10/resnet18/WaNet, poison_rate=0.01, s=0.8：asr=0.888，transfer_rate=0.0416，目标域 clean ACC 0.719。这不是攻击未建立，而是源域成功、跨域迁移失败。相反，MNIST-M 上很多高迁移高隐蔽反例同时有高 ASR 和高目标域 clean ACC，因此不能用“攻击失败”或“分类不可靠”排除。

目标域 clean ACC 对 Tiny 是主要限制：Tiny 的 target clean ACC 均值 0.360，代表点约 0.35-0.42，远低于 MNIST-M 和 CIFAR。因此 Tiny 上结论应写得更谨慎：它支持 trade-off，但迁移 ASR 的解释要附带目标域分类可靠性限制。源域 clean ACC 已提取，但本轮没有干净模型 baseline，因此只能报告 poisoned model 的绝对 clean ACC，不能正式计算 clean ACC drop。

代表配置

下面的表只列关键代表点。wTPR/wAUC 越高越容易检测，stAUC=1-wAUC 越高越隐蔽。

类别	dataset	arch	attack	poison_rate	train	test	transfer
高迁移 +高检测	tiny_imagenet	resnet18	basic	0.050	0.9	0.9	0.999
高迁移 +高检测	cifar10	mobilenet	basic	0.010	1.0	1.0	1.000
高迁移 +高检测	mnistm	resnet18	basic	0.050	0.3	0.3	1.000
低迁移 +低检测/ 攻击失 败	mnistm	mobilenet	adaptive_patch	0.005	0.2	0.2	0.287
低迁移 +低检测/ 攻击失 败	mnistm	mobilenet	WaNet	0.010	1.4	1.4	0.078
低迁移 +低检测/ 攻击失 败	mnistm	resnet18	upgd	0.005	8.0	8.0	0.003
高迁移 +低检测 反例	mnistm	resnet18	upgd	0.050	20.0	20.0	0.998

类别	dataset	arch	attack	poison_rate	train	test	transfer
高迁移 +低检测 反例	mnistm	mobilenet	belt	0.010	0.2	0.2	0.995
高迁移 +低检测 反例	tiny_imagenet	vgg	upgd	0.001	24.0	24.0	0.896
高 ASR+低 transfer	cifar10	resnet18	WaNet	0.010	0.8	0.8	0.041
高 ASR+低 transfer	cifar10	mobilenet	WaNet	0.050	0.8	0.8	0.050
高 ASR+低 transfer	tiny_imagenet	vgg	WaNet	0.010	0.6	0.6	0.579

BELT 表中 train=0.2 是 mask_rate，不是 alpha；例如上表的 MNIST-M BELT 反例实际还有 alpha=0.35, cover_rate=0.5。这是上一轮确认过的 BELT 参数口径。

最终判断

可以正式回答主问题：

是的，从总体统计看，高迁移性的攻击更容易被四种防御检测，隐蔽性更差；AUC 和 TPR 两个口径方向一致，AUC 口径更稳健。

但这个结论必须带限定：

- 1. 过滤攻击失败点后，trade-off 仍存在但变弱，说明不能把低 ASR、低 transfer、低 detection 的点解释成“成功隐蔽”。
- 2. basic/BadNet 和 adaptive_patch 最支持 trade-off；它们是论文中最清晰的正例。
- 3. UPGD、BELT 和部分 blend/WaNet 是重要反例，尤其在 MNIST-M -> MNIST 上能高迁移且较隐蔽。
- 4. Tiny-ImageNet -> ImageNetV2 对应类别支持 trade-off，但目标域 clean ACC 较低，需要在论文中作为限制说明。
- 5. 模型架构会调节结论：VGG 相关性最强，ResNet18 平均迁移和检测强度最高，MobileNet 同时更容易出现极端高检测点和 MNIST-M 上的高隐蔽反例。