

GPT分析结论

1. 核心结论

1. 总体上存在“迁移性越强，越容易被检测，隐蔽性越差”的趋势。
在全部 1491 个 no-NC 配置上，`transfer_rate` 与 `weighted_TPR` 正相关，Pearson/Spearman 为 `+0.599 / +0.633`；与 `weighted_AUC` 也正相关，为 `+0.660 / +0.684`。等价地，`transfer_rate` 与 `stealth_TPR_w`、`stealth_AUC_w` 分别负相关。这直接支持主问题中的 trade-off。
2. TPR 和 AUC 口径方向一致，但 AUC 更稳定。
AUC 口径在全球、分数据集、分模型和多数攻击内都给出更强、更平滑的相关性；TPR 依赖防御阈值，容易受阈值选择和检测分数分布影响。因此主文更适合以 `weighted_AUC / stealth_AUC_w` 为主结论，`weighted_TPR / stealth_TPR_w` 作为阈值化检测补充。
3. 这个 trade-off 不是绝对规律，而是统计趋势和条件性现象。
在 `asr >= 0.5` 的有效攻击子集上，`transfer_rate` 与 `weighted_AUC` 仍正相关，但从全量的 `+0.660` 降到 `+0.383`。这说明趋势仍存在，但全局强度部分来自“攻击未建立成功”的配置：这些配置常常同时低迁移、低检测、高 stealth，不能被解释成真正成功的隐蔽攻击。
4. trade-off 主要由局部 patch 类攻击驱动。
`basic/BadNet`、`adaptive_patch`、部分 `belt` 在迁移成功时通常也显著更容易被 STRIP、SentiNet、IBD-PSC、SCaLe-Up 检测。尤其 `basic` 平均 `transfer_rate=0.885`、`weighted_AUC=0.852`、`stealth_AUC_w=0.148`，是最清晰的“高迁移低隐蔽”代表。
5. 反例主要来自非局部或经过适应性训练的攻击。
UPGD、BELT、部分 Blend 和 WaNet 在 MNIST-M -> MNIST 上能出现高迁移且较高隐蔽的配置。例如 `mnistm/resnet18/upgd`, `eps=20`, `poison_rate=0.05` 的 `transfer_rate=0.9985`，但 `weighted_AUC=0.3608`、`stealth_AUC_w=0.6392`，且 `asr=0.889`，不是攻击失败。
6. 数据集和模型显著调节结论。
CIFAR-10 -> STL-10 和 Tiny-ImageNet -> ImageNetV2 对应类别更支持 trade-off；MNIST-M -> MNIST 同样有正相关，但反例最多。模型上，VGG 的相关性最强，ResNet18 平均迁移和检测强度最高，MobileNet 更容易出现 MNIST-M 上的高迁移高隐蔽反例。
7. 参数趋势支持“强触发器更迁移但也更易检测”的机制解释。
对 `basic/blend/adaptive_blend/upgd`，触发器强度或优化强度增大通常提升 ASR 和 `transfer_rate`，同时也提高 `weighted_AUC/weighted_TPR`。但 UPGD 和 SIG 的检测强度增长弱于迁移增长，是它们产生反例的重要原因。

2. 数据集层面解释

CIFAR-10 -> STL-10

CIFAR-10 -> STL-10 上 trade-off 很明显。全量 transfer_rate 与 weighted_AUC 的 Pearson/Spearman 为 +0.706 / +0.751；在 asr >= 0.5 后仍有 +0.590 / +0.669。这说明即使排除攻击未建立成功的点，高迁移配置仍更容易被检测。

迁移性高的攻击主要是 basic、upgd、blend 和部分 belt/adaptive_patch。其中 basic 最典型：局部 patch 强度高时，transfer_rate 常接近 1.0，同时 weighted_AUC 接近 0.97，stealth_AUC_w 低到 0.02-0.03。这与机制一致：固定局部 patch 在源域和目标域中都提供强 target shortcut，但也形成稳定、显著、缩放后仍有效的检测信号。

高隐蔽攻击主要是 SIG、部分 adaptive_blend 和部分低强度 WaNet/UPGD，但很多低迁移低检测点其实源域 ASR 也低，属于弱攻击或攻击未建立成功，不能被解释为真正“隐蔽但不可迁移”。

CIFAR 上最重要的迁移瓶颈是 WaNet。多个 WaNet 配置源域 asr 很高但 transfer_rate 很低，例如 cifar10/resnet18/WaNet, poison_rate=0.01, s=0.8: asr=0.8877, transfer_rate=0.0416，目标域 clean ACC 0.7186。这说明空间形变后门在 CIFAR 源域建立成功，但对 STL-10 的跨域迁移失败。可能原因是 STL-10 图像先从 96x96 压缩到 32x32，空间形变 cue 与源域训练分布不完全一致；同时 STL-10 类别筛选和图像统计也改变了模型依赖的几何特征。

CIFAR 的目标域 clean ACC 均值约 0.648，可解释性中等；它低于 MNIST-M -> MNIST，但明显高于 Tiny-ImageNet -> ImageNetV2 对应类别。因此 CIFAR 结果可较可靠地说明 trade-off，但不能直接推广到所有迁移设置，尤其不能推广到空间形变类攻击。

Tiny-ImageNet -> ImageNetV2 对应类别

Tiny-ImageNet -> ImageNetV2 对应类别上 trade-off 也明显。全量 transfer_rate 与 weighted_AUC 为 +0.705 / +0.754；asr >= 0.5 后仍为 +0.484 / +0.514。这里的高迁移攻击主要是 basic、adaptive_patch、belt、blend 和高强度 WaNet。它们大多也更容易被检测，尤其 basic 和 adaptive_patch。

Tiny 上的 basic 和 adaptive_patch 是最强 trade-off 证据：basic 平均 transfer_rate=0.882、weighted_AUC=0.889；adaptive_patch 平均 transfer_rate=0.849、weighted_AUC=0.879。局部 patch 在 200 类目标空间里仍能产生强目标类 shortcut，但这个 shortcut 也被 SentiNet 的显著区域、STRIP 的低熵稳定性、IBD-PSC 的内部行为异常捕捉。

高隐蔽攻击主要是 SIG 和 upgd。它们不是局部显著 patch，检测信号更分散。Tiny 上存在高迁移高隐蔽反例，例如 tiny_imagenet/vgg/upgd, poison_rate=0.001, eps=24: transfer_rate=0.8960, weighted_AUC=0.4124, stealth_AUC_w=0.5876, asr=0.7459。这说明优化扰动能在一定程度上打破“高迁移必然低隐蔽”的规律。

类别映射是 Tiny 结论可信的关键前提。代码和结果文件使用 tiny_target_domain / target_domain 命名，但上一轮确认过，当前目标域路径是 /workspace/data/imagenetv2-

matched-frequency-tiny-organized，并通过 `class_to_idx` 与 Tiny-ImageNet train 的 `wnid` 排序对齐。因此论文中应表述为“Tiny-ImageNet -> ImageNetV2 对应类别”，同时说明代码文件名仍沿用 `tiny_target_domain`。如果未来复现实验换了 target domain，必须重新验证类别映射。

限制是 Tiny 的目标域 clean ACC 均值只有 0.360。这不影响“检测强度和 `transfer_rate` 正相关”的统计事实，但会影响对绝对 `transfer_rate` 的语义解释：当目标域分类本身不够可靠时，高 ASR 可能部分受目标域分类偏差影响。因此 Tiny 的结论应写成支持 trade-off，但带有目标域 clean ACC 限制。

MNIST-M -> MNIST

MNIST-M -> MNIST 上总体也支持 trade-off，但它是反例最多的数据集。全量 `transfer_rate` 与 `weighted_AUC` 为 +0.699 / +0.760；`asr >= 0.5` 后仍为 +0.458 / +0.561。方向没有改变，但强度弱于全量，说明大量低 ASR 点会放大全局趋势。

MNIST-M -> MNIST 的高迁移攻击很多：`basic`、`blend`、`belt`、`WaNet`、`UPGD` 在合适参数下都能达到非常高的 `transfer_rate`。这是因为源域和目标域共享数字类别结构，域差异主要是背景/风格，而不是语义空间变化。触发器一旦在 MNIST-M 上建立，对 MNIST 的迁移条件相对更有利。

但 MNIST-M 上高迁移并不总是低隐蔽。最重要的反例来自 `UPGD`、`BELT` 和部分 `Blend/WaNet`。例如 `UPGD` 在 MNIST-M 上多个 `eps=20/24` 配置 `transfer_rate` 接近 1.0，但 `weighted_AUC` 仍低于全局低检测四分位附近。`BELT` 也有类似现象：局部 patch 按理应容易被检测，但 `cover samples` 与 `CenterLoss` 训练削弱了简单的特征分离，使部分配置高迁移且低检测。

MNIST-M 的目标域 clean ACC 均值 0.942，源域 clean ACC 均值 0.984，因此这些反例比较可信，不能用“目标域分类不可靠”排除。相反，MNIST-M 的 SIG 多数低迁移低检测点是攻击失败：例如 MNIST-M 的 SIG 有大量 `asr < 0.3` 的点，不能被解释为成功且隐蔽的迁移攻击。

MNIST-M 结论不能直接推广到 CIFAR/Tiny。它说明在较近域迁移和较简单任务中，某些非局部或适应性机制可以同时保持迁移和隐蔽，从而打破平均 trade-off。

3. 攻击方法和攻击家族解释

八种攻击

`belt` / `BELT`:

`BELT` 是局部 patch 触发器，但训练时包含 `cover samples`，并使用 `BELT` 增强模型和 `CenterLoss`，使中毒/cover/clean 特征关系不同于普通 `BadNet`。整体上 `BELT` 迁移性强，平均 `transfer_rate=0.767`，检测强度也偏高，`weighted_AUC=0.708`，因此平均支持 trade-off。但它不是普通局部 patch：MNIST-M 上存在高迁移高隐蔽反例，例如 `MobileNet/BELT` `transfer_rate=0.9950`、`weighted_AUC=0.3788`、`asr=0.9136`。机制解释是：`BELT` 的触发

器仍能建立稳定 target shortcut，但 cover samples 和 CenterLoss 降低了某些防御可利用的 clean/poison 分离。参数上 BELT 的 train_param_value 是 mask_rate，而 alpha 单独在 alpha 列；当前结果中 BELT cover 多为 0.5，因此很难从现有表中单独估计 cover_rate 的因果作用。

upgd / UPGD:

UPGD 是优化得到的 universal perturbation，不是局部 patch，也没有明显显著区域。全量均值看它迁移中等，transfer_rate=0.569、weighted_AUC=0.545；但在 asr $\geq$ 0.5 后，transfer_rate 升到 0.837，而 weighted_AUC=0.618，仍低于局部 patch 家族。它是最重要的 trade-off 反例来源之一。eps 增大时，UPGD 的迁移明显增强，Spearman eps $\rightarrow$ transfer_rate 为 +0.611，但 eps $\rightarrow$ weighted_AUC 只有 +0.212，说明强度提升带来的检测代价相对较小。这与机制一致：优化扰动能产生跨样本 target cue，但不一定形成 SentiNet 可定位的局部区域，也不一定在 STRIP/Scale-Up 下表现为极强的输入级稳定性。

basic / BadNet:

BadNet 是固定局部 patch baseline，是最强 trade-off 正例。平均 asr=0.848、transfer_rate=0.885、weighted_AUC=0.852、stealth_AUC_w=0.148。它在三个数据集和三种模型上都相对稳定：迁移强，也最容易被检测。SentiNet 对 basic 尤其强，raw AUC 均值约 0.983、raw TPR 约 0.970；STRIP 和 IBD-PSC 也较强。这符合机制：局部 patch 是高可学习、高可复用的 shortcut，但同时显著、稳定、缩放后仍有效。

blend / Blend:

Blend 是全图混合触发器。它整体迁移较强，transfer_rate=0.757，检测中等偏高，weighted_AUC=0.637。它支持 trade-off，但弱于 BadNet，因为全图 trigger 不形成紧凑显著区域，SentiNet 对它较弱，SentiNet raw AUC 约 0.500、TPR 约 0.122。Blend 的 alpha 趋势很清晰：alpha $\rightarrow$ transfer_rate 为 +0.624，alpha $\rightarrow$ weighted_AUC 为 +0.507，即更强 blend 更迁移，也更容易检测。MNIST-M 上中等 alpha 的 Blend 可成为高迁移高隐蔽反例，说明全局低显著 trigger 能部分打破 trade-off。

SIG:

SIG 是全局正弦信号。全量上它 asr=0.341、transfer_rate=0.302、weighted_AUC=0.486，看起来隐蔽但迁移弱。但这主要受低 ASR 点影响，尤其 MNIST-M 上 SIG 大量攻击未建立成功。有效攻击子集里，SIG 的 transfer_rate=0.717、weighted_AUC=0.556，显示一定迁移能力和较高隐蔽性。delta $\rightarrow$ transfer_rate 为 +0.366，但 delta $\rightarrow$ weighted_AUC 只有 +0.052，说明增强正弦幅度不一定显著增加 AUC 检测强度。机制上，SIG 不产生局部显著区域，SentiNet 和 STRIP 都不稳定；但若模型没有充分学习该全局频域 cue，则 ASR 和 transfer 都低。

adaptive_patch:

Adaptive-Patch 使用多个局部 patch 和 cover samples。它平均 transfer_rate=0.625、weighted_AUC=0.671，支持 trade-off。它的 SentiNet raw AUC 高达约 0.944、TPR 约 0.912，说明多 patch 训练并没有消除“局部显著触发器”这个核心检测信号。需要注意，上一轮

代码确认过 adaptive_patch 的 test_alpha 在代码中不是像 basic/blend 那样直接控制测试强度，部分 train_param_value/test_param_value 更像配置标记。因此参数解释要谨慎。总体上，它比 basic 更适应，但仍属于局部 patch 家族，迁移成功时也容易检测。

adaptive_blend：

Adaptive-Blend 是 masked/full-image blend，训练时带 cover samples 和 piece masking。它平均 transfer_rate=0.598、weighted_AUC=0.566、stealth_AUC_w=0.434，比普通 blend 更隐蔽，但迁移性也略弱。alpha 对它影响很强：alpha -> transfer_rate 为 +0.734，alpha -> weighted_AUC 为 +0.468。这支持“更强触发器更迁移但更易检测”的机制解释。cover_rate 在现有结果中与检测强度轻微正相关，但不能简单解释为 cover 导致更易检测，因为 cover_rate 与其他配置共同变化。论文中适合把它概括为“降低局部显著性、缓和但不消除 trade-off 的 blend 变体”。

WaNet：

WaNet 是全局空间形变。它整体 transfer_rate=0.566、weighted_AUC=0.580，但数据集依赖非常强。CIFAR -> STL 上大量 WaNet 是高 ASR 低 transfer，说明源域后门成功但空间形变 cue 不跨域；MNIST-M 和 Tiny 上高强度 WaNet 可迁移较好。检测上，SentiNet 对 WaNet 较弱，因为没有局部 patch；Scale-Up 和 IBD-PSC 更敏感一些，因为形变可能导致缩放一致性或内部行为异常。poison_rate 对 WaNet 影响强：poison_rate -> asr 为 +0.823，poison_rate -> transfer_rate 为 +0.434，poison_rate -> weighted_AUC 为 +0.587，说明增加中毒比例同时提升攻击和检测风险。

攻击家族总结

家族	攻击	mean transfer	mean wAUC	mean stAUC	论文概括
localized_patch	basic, adaptive_patch, belt	0.785	0.763	0.237	最典型高迁移低隐蔽家族
blended_trigger	blend, adaptive_blend	0.678	0.602	0.398	中高迁移、中等检测，存在反例
global_signal	SIG	0.302	0.486	0.514	高隐蔽但常攻击未建立
global_spatial	WaNet	0.566	0.580	0.420	数据集依赖强，CIFAR 上迁移瓶颈明显
optimized_perturbation	upgd	0.569	0.545	0.455	最可能打破 trade-off 的家族

局部 patch 家族最适合作为“高迁移低隐蔽”的代表。固定或多样化 patch 都能形成强 shortcut，但也最容易被显著区域、熵稳定性、缩放一致性和内部行为检测捕捉。

global_signal 最适合作为“高隐蔽低迁移/攻击未建立”的代表，但必须用 ASR 控制，不能把失败点当成成功隐蔽。

optimized_perturbation 最可能打破 trade-off，因为它能通过优化形成迁移性，同时不产生局部显著触发器，且检测强度随 eps 增长不如迁移增长明显。

4. 防御方法解释

STRIP

STRIP 的机制是对输入进行多次 superimpose，观察预测熵。强后门触发器如果让模型在扰动后仍稳定输出目标类，就会产生低熵，被判为可疑。全局均值上 STRIP raw AUC 约 0.637，raw TPR 约 0.272，与 transfer_rate 的 AUC 相关性约 +0.655，是总体 trade-off 的重要贡献者。

STRIP 最容易检测强触发器和稳定目标类输出：basic 的 STRIP AUC 约 0.868，blend 约 0.700，belt 约 0.691。它较不擅长 SIG、WaNet、UPGD 的部分配置，因为这些触发器可能在 superposition 下被破坏，或者不会稳定产生极低熵。STRIP 的 AUC 比 TPR 更能反映检测分数排序；TPR 低说明固定阈值下未必抓住全部可分性。

SentiNet

SentiNet 依赖 GradCAM/显著区域和区域移植后的行为分析，因此天然偏向局部显著触发器。它对 basic 和 adaptive_patch 最强：basic 的 SentiNet AUC/TPR 约 0.983/0.970，adaptive_patch 约 0.944/0.912。这也是 localized_patch 家族低隐蔽性的主要来源之一。

SentiNet 对全图 blend、SIG、WaNet、UPGD 明显较弱：blend 的 SentiNet AUC 约 0.500、TPR 约 0.122；WaNet 约 0.490/0.125；SIG 约 0.443/0.087。这说明某些攻击看起来高隐蔽，可能不是完全绕过所有检测，而是绕过了“局部显著区域”这一路信号。相反，patch 攻击看起来低隐蔽，也部分是因为 SentiNet 对它非常强，但 basic 在 STRIP 和 IBD-PSC 下也强，所以不是单一防御造成。

IBD-PSC

IBD-PSC 检测的是 BatchNorm 参数缩放后的 prediction consistency / 内部行为异常。它不直接依赖输入是否有局部 patch，因此能补充 SentiNet 的盲区。全局 IBD-PSC AUC 约 0.658，TPR 约 0.532，是四个防御里平均 TPR 最高的方法。

IBD-PSC 对 basic、belt、blend、WaNet 都较敏感：AUC 分别约 0.856、0.811、0.703、0.642。它对 UPGD 平均较弱，AUC 约 0.506，说明优化扰动不一定造成容易被 BN 缩放捕捉的内部一致性异常。IBD-PSC 可能导致某些非局部攻击在 weighted AUC 中并不完全隐蔽，但它也有阈值敏感问题：在 MNIST-M 上 IBD-PSC 的 TPR 较高，而 AUC 只是中等，说明固定阈值和分数排序不总是一致。

SCaLe-Up

SCaLe-Up 检测输入缩放后预测是否保持异常一致。如果触发器在强度缩放和 clip 后仍能稳定触发目标类，就更容易被检测。全局 Scale-Up AUC 约 0.613，TPR 约 0.353。

Scale-Up 在 CIFAR 上特别强，CIFAR 平均 Scale-Up AUC/TPR 约 0.733/0.592，高于其在 MNIST-M 上的 0.468/0.227。它对 basic、blend、WaNet 较敏感，因为 patch/blend/空间形变可能在缩放后仍保持预测一致性；对 SIG、adaptive_blend、UPGD 则较弱或中等。Scale-Up 可以解释“强触发器更容易检测”的一部分机制：强 trigger 不只是原图有效，在缩放扰动后也更稳定。

5. TPR vs AUC 口径比较

weighted_TPR 和 weighted_AUC 给出的攻击排序高度一致，但不完全相同。

AUC 检测强度排序为：

```
basic > belt > adaptive_patch > blend > WaNet > adaptive_blend > upgd > SIG
```

TPR 检测强度排序为：

```
basic > adaptive_patch > belt > blend > WaNet > upgd > adaptive_blend > SIG
```

主要差异有两个：

- adaptive_patch 在 TPR 下比 BELT 更靠前，因为 SentiNet 对 adaptive_patch 的阈值化检测非常强。
- BELT 在 AUC 下比 adaptive_patch 更靠前，说明 BELT 的检测分数整体可分性较高，但固定阈值下未必总能转化为更高 TPR。
- UPGD 与 adaptive_blend 的位置也有轻微交换，说明两者的检测分数分布和固定阈值表现不同。

AUC 更适合作为主文结论，因为它不依赖某一个阈值。TPR 应同时报告，因为它反映实际部署阈值下能检出多少 poisoned 样本。如果两者不一致，论文应写成：“AUC 显示检测分数具有更强可分性，而 TPR 显示在当前阈值设置下的实际检出率；两者方向一致时结论更可靠，方向不一致时应避免过度解释。”

6. 模型与参数影响

模型架构会调节 trade-off。VGG 上全局相关性最强，transfer_rate 与 weighted_AUC 的 Spearman 为 +0.726；ResNet18 平均迁移性和检测强度最高，mean transfer=0.691、mean wAUC=0.661；MobileNet 上高迁移高隐蔽反例更多，尤其集中在 MNIST-M 的 UPGD、BELT 和 Blend。

架构差异可能通过两条路径影响结果。第一，不同模型对触发器 shortcut 的学习偏好不同，局部 patch、全图 blend、空间形变和优化扰动在不同架构中形成的特征依赖不一样。第二，防御本身

也依赖模型行为：SentiNet 依赖显著区域，IBD-PSC 依赖 BN 缩放响应，STRIP/Scale-Up 依赖预测稳定性。不同架构的置信度、特征局部性和 BN 行为都会改变检测结果。因此论文中不应把全局相关性写成架构无关规律。

参数趋势总体支持 trade-off：

- basic 的 alpha 越大，迁移越强，检测越强：alpha -> transfer_rate 约 +0.620，alpha -> weighted_AUC 约 +0.478。
- blend 同样明显：alpha -> transfer_rate 约 +0.624，alpha -> weighted_AUC 约 +0.507。
- adaptive_blend 更明显：alpha -> transfer_rate 约 +0.734，alpha -> weighted_AUC 约 +0.468。
- UPGD 的 eps -> transfer_rate 约 +0.611，但 eps -> weighted_AUC 只有 +0.212，说明它能在某些区间提升迁移而不成比例增加检测，是反例的重要参数机制。
- SIG 的 delta -> transfer_rate 为 +0.366，但 delta -> weighted_AUC 只有 +0.052，说明全局正弦信号的检测代价增长较慢，但低 ASR 限制了它作为成功攻击的解释。
- WaNet 的 s 趋势较弱，但 poison_rate 对 WaNet 非常敏感：poison_rate 增大明显提升 ASR、transfer 和检测强度。

cover_rate 的结论要谨慎。Adaptive-Patch 的 cover_rate 与 transfer/detection 轻微负相关，符合“cover 可能帮助隐蔽但牺牲攻击”的直觉；Adaptive-Blend 的 cover_rate 与检测略正相关；WaNet 的 cover_rate 与多个指标强相关，但可能与 poison_rate 或配置网格耦合，不能直接作因果解释。BELT 中 cover_rate 基本固定为 0.5，无法从当前结果估计趋势。

7. 特殊点和反例

类型	dataset	arch	attack	poison_rate	参数	transfer
高迁移 +高检测	tiny_imagenet	resnet18	basic	0.050	alpha=0.9	0.999
高迁移 +高检测	cifar10	mobilenet	basic	0.010	alpha=1.0	1.000
高迁移 +高检测	mnistm	resnet18	basic	0.050	alpha=0.3	1.000
低迁移 +低检测	mnistm	mobilenet	adaptive_patch	0.005	alpha=0.2	0.287
低迁移 +低检测	mnistm	mobilenet	WaNet	0.010	s=1.4	0.078

类型	dataset	arch	attack	poison_rate	参数	transfer
高迁移 +低检测 反例	mnistm	resnet18	upgd	0.050	eps=20	0.996
高迁移 +低检测 反例	mnistm	mobilenet	belt	0.010	mask=0.2, alpha=0.35, cover=0.5	0.995
高迁移 +低检测 反例	tiny_imagenet	vgg	upgd	0.001	eps=24	0.896
高 ASR+低 transfer	cifar10	resnet18	WaNet	0.010	s=0.8	0.041
高 ASR+低 transfer	cifar10	mobilenet	WaNet	0.050	s=0.8	0.050
低 ASR+低 transfer	mnistm	mobilenet	SIG	0.010	delta=4	0.001

这些点说明：支持 trade-off 的典型配置主要是强局部 patch；打破 trade-off 的反例主要是 UPGD、BELT 和部分全局/空间触发器；高 ASR 低 transfer 的点主要暴露跨域迁移瓶颈，而不是检测问题。

8. 控制指标和实验限制

ASR 控制是必要的。低 transfer_rate 如果同时低 asr，不能解释为“迁移性差”，只能说明攻击本身没有建立成功。典型包括 MNIST-M 上的大量 SIG、低强度 UPGD、低强度 adaptive_patch。相反，高 asr 低 transfer_rate 才是真正的迁移瓶颈，CIFAR 的 WaNet 是最突出例子。

$transfer_retention = transfer_rate / asr$ 提供了补充视角。在 $asr \geq 0.5$ 子集上，CIFAR WaNet 的 retention 只有约 0.270，说明源域成功但迁移严重衰减；MNIST-M 的 WaNet、Blend、UPGD retention 常接近或超过 1.0，说明目标域上触发器保持得很好，甚至可能受到目标域分类偏差或任务简化影响。retention 不能替代 transfer_rate，但能帮助区分“攻击弱”和“迁移弱”。

ACC 数据本轮已回溯到全部配置：目标域 clean ACC 和源域 clean ACC 都可用。限制是我们没有引入干净模型 baseline，因此只能报告 poisoned model 的绝对 clean ACC，不能正式计算 clean ACC drop。Tiny-ImageNet -> ImageNetV2 对应类别的目标域 clean ACC 较低，是最重要的解释限制。MNIST-M 的 target ACC 高，反例可信度最高；CIFAR 居中；Tiny 结论需要附带分类可靠性说明。

Tiny 的类别映射是关键实验前提。当前结果文件命名使用 `tiny_target_domain`，但实际目标域路径为 ImageNetV2 matched-frequency 的 Tiny 对应类别组织集，并已做 `class_to_idx` / `wnid` 对齐。论文中必须说明这一点，避免读者误以为是另一个未定义 target domain。

9. 论文表述建议

可直接放进论文的结果分析版本：

在不考虑 Neural Cleanse、仅使用 STRIP、SentiNet、IBD-PSC 和 SCaLe-Up 四种防御的设定下，我们观察到迁移性与隐蔽性之间存在显著的统计性 trade-off。具体而言，目标域攻击成功率 `transfer_rate` 与四种防御的加权检测强度呈正相关：在全部配置上，`transfer_rate` 与 `weighted_AUC` 的 Pearson/Spearman 相关性分别为 0.660/0.684，与 `weighted_TPR` 的相关性分别为 0.599/0.633；相应地，`transfer_rate` 与 `stealth_AUC_w` 和 `stealth_TPR_w` 呈负相关。这表明，在总体趋势上，迁移性更强的后门攻击更容易暴露于现有检测方法之下。该趋势在 CIFAR-10 -> STL-10、Tiny-ImageNet -> ImageNetV2 对应类别和 MNIST-M -> MNIST 三个迁移设置中均成立，并且在 `asr >= 0.5` 的有效攻击子集上仍保持同向关系。机制上，该现象主要由局部 patch 类攻击驱动：BadNet 和 Adaptive-Patch 能形成稳定且跨域复用的目标类 shortcut，但也更容易被显著区域、熵稳定性、缩放一致性和模型内部行为检测捕捉。

更谨慎、避免过度结论的版本：

然而，该 trade-off 并非绝对规律，而是受攻击机制、数据域差异、模型架构和参数强度共同调节的条件性现象。过滤掉源域 ASR 较低的失败攻击后，相关性仍然存在但明显减弱，说明全局趋势部分受到弱攻击配置的影响。此外，UPGD、BELT 以及部分 Blend/WaNet 配置在 MNIST-M -> MNIST 上能够同时取得较高迁移性和较高隐蔽性，构成对简单 trade-off 叙述的反例。这些反例通常不产生紧凑局部显著区域，或通过 cover samples、CenterLoss、优化扰动等机制削弱检测信号。因此，更准确的结论是：高迁移攻击在统计上更可能被检测，尤其是局部 patch 家族；但通过非局部触发器、优化扰动或适应性训练，可以在特定数据集、模型和参数区间内部分打破迁移性与隐蔽性之间的 trade-off。Tiny-ImageNet -> ImageNetV2 对应类别实验还应结合类别映射正确性和较低目标域 clean ACC 进行谨慎解释。